

Линейный и нелинейный регрессионный анализ

- **Введение**

- Введение
- Постановка задачи регрессионного анализа

- Введение
- Постановка задачи регрессионного анализа
- Линейные модели. Свойства оценок по методу наименьших квадратов

- Введение
- Постановка задачи регрессионного анализа
- Линейные модели. Свойства оценок по методу наименьших квадратов
- Доказательство теоремы Гаусса-Маркова

- Введение
- Постановка задачи регрессионного анализа
- Линейные модели. Свойства оценок по методу наименьших квадратов
- Доказательство теоремы Гаусса-Маркова
- Нелинейные модели. Асимптотические свойства оценок параметров

Началом систематического развития теории планирования эксперимента явились работы выдающегося английского статистика сэра Рональда Фишера, вошедшие в его широко известную монографию (Fisher, 1935).

Началом систематического развития теории планирования эксперимента явились работы выдающегося английского статистика сэра Рональда Фишера, вошедшие в его широко известную монографию (Fisher, 1935).

В этих работах комбинаторные методы применялись для выбора уровней факторов с целью повышения информативности эксперимента в задачах дисперсионного анализа. Первоначальным мотивом этих исследований была проблема повышения урожайности сельскохозяйственных культур.

Началом систематического развития теории планирования эксперимента явились работы выдающегося английского статистика сэра Рональда Фишера, вошедшие в его широко известную монографию (Fisher, 1935).

В этих работах комбинаторные методы применялись для выбора уровней факторов с целью повышения информативности эксперимента в задачах дисперсионного анализа. Первоначальным мотивом этих исследований была проблема повышения урожайности сельскохозяйственных культур.

Однако глубокие математические результаты, полученные Фишером, послужили источником для развития самостоятельной ветви математической статистики, имеющей свою внутреннюю логику и широчайший спектр приложений.

В 50-е годы XX века, в работах американских математиков Г. Элвинга (Elfving, 1952) и Г. Чернова (Chernoff, 1953) возникло новое направление, получившее название теории оптимального планирования эксперимента.

В 50-е годы XX века, в работах американских математиков Г. Элвинга (Elfving, 1952) и Г. Чернова (Chernoff, 1953) возникло новое направление, получившее название теории оптимального планирования эксперимента.

С конца 50-х годов эта теория систематически развивалась в работах американских математиков Дж. Кифера и Дж. Вольфовица, а с конца 60-х значительный вклад к ее развитию внесли российские математики В.В. Федоров, Г.К. Круг и многие другие.

В 50-е годы XX века, в работах американских математиков Г. Элвинга (Elfving, 1952) и Г. Чернова (Chernoff, 1953) возникло новое направление, получившее название теории оптимального планирования эксперимента.

С конца 50-х годов эта теория систематически развивалась в работах американских математиков Дж. Кифера и Дж. Вольфовица, а с конца 60-х значительный вклад к ее развитию внесли российские математики В.В. Федоров, Г.К. Круг и многие другие.

В основе этой теории лежит понятие плана эксперимента как дискретной вероятностной меры, а под оптимальным планом понимается план, доставляющий экстремальное значение некоторой выпуклой (или вогнутой) функции, заданной на множестве информационных матриц.

В 50-е годы XX века, в работах американских математиков Г. Элвинга (Elfving, 1952) и Г. Чернова (Chernoff, 1953) возникло новое направление, получившее название теории оптимального планирования эксперимента.

С конца 50-х годов эта теория систематически развивалась в работах американских математиков Дж. Кифера и Дж. Вольфовица, а с конца 60-х значительный вклад к ее развитию внесли российские математики В.В. Федоров, Г.К. Круг и многие другие.

В основе этой теории лежит понятие плана эксперимента как дискретной вероятностной меры, а под оптимальным планом понимается план, доставляющий экстремальное значение некоторой выпуклой (или вогнутой) функции, заданной на множестве информационных матриц.

Родственное направление, связанное с исследованием поверхности отклика для нахождения его экстремальных значений, было инициировано в работах американского статистика Дж. Бокса В России это направление развивалось в работах В.В. Налимова и его учеников (первая российская книга на эту тему – Налимов, Чернова, 1965).

Постановка задачи регрессионного анализа

Рассмотрим уравнение:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N,$$

где

- $y_1, \dots, y_N \in \mathbb{R}$ — результаты наблюдений,

Постановка задачи регрессионного анализа

Рассмотрим уравнение:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N,$$

где

- $y_1, \dots, y_N \in \mathbb{R}$ — результаты наблюдений,
- $x_1, \dots, x_N \in \mathcal{X}$ — условия проведения эксперимента (могут повторяться),

Постановка задачи регрессионного анализа

Рассмотрим уравнение:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N,$$

где

- $y_1, \dots, y_N \in \mathbb{R}$ — результаты наблюдений,
- $x_1, \dots, x_N \in \mathcal{X}$ — условия проведения эксперимента (могут повторяться),
- $\mathcal{X}$ — некоторое заданное множество, например, ограниченное замкнутое подмножество конечномерного евклидова пространства,

Постановка задачи регрессионного анализа

Рассмотрим уравнение:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N,$$

где

- $y_1, \dots, y_N \in \mathbb{R}$ — результаты наблюдений,
- $x_1, \dots, x_N \in \mathcal{X}$ — условия проведения эксперимента (могут повторяться),
- $\mathcal{X}$ — некоторое заданное множество, например, ограниченное замкнутое подмножество конечномерного евклидова пространства,
- Функция $\eta(x, \theta) : \mathcal{X} \times \Theta \rightarrow \mathbb{R}$ называется регрессионной моделью или функцией регрессии,

Постановка задачи регрессионного анализа

Рассмотрим уравнение:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N,$$

где

- $y_1, \dots, y_N \in \mathbb{R}$ — результаты наблюдений,
- $x_1, \dots, x_N \in \mathcal{X}$ — условия проведения эксперимента (могут повторяться),
- $\mathcal{X}$ — некоторое заданное множество, например, ограниченное замкнутое подмножество конечномерного евклидова пространства,
- Функция $\eta(x, \theta) : \mathcal{X} \times \Theta \rightarrow \mathbb{R}$ называется регрессионной моделью или функцией регрессии,
- $\theta = (\theta_1, \dots, \theta_m)^T \in \Theta$ — вектор неизвестных параметров,

Постановка задачи регрессионного анализа

Рассмотрим уравнение:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N,$$

где

- $y_1, \dots, y_N \in \mathbb{R}$ — результаты наблюдений,
- $x_1, \dots, x_N \in \mathcal{X}$ — условия проведения эксперимента (могут повторяться),
- $\mathcal{X}$ — некоторое заданное множество, например, ограниченное замкнутое подмножество конечномерного евклидова пространства,
- Функция $\eta(x, \theta) : \mathcal{X} \times \Theta \rightarrow \mathbb{R}$ называется регрессионной моделью или функцией регрессии,
- $\theta = (\theta_1, \dots, \theta_m)^T \in \Theta$ — вектор неизвестных параметров,
- $\varepsilon_1, \dots, \varepsilon_N$ — случайные ошибки.

Это уравнение называется уравнением регрессии.

Уже в простейшем случае, когда

$$\eta(x, \theta) = \theta_1 + \theta_2 x$$

уравнение регрессии имеет многочисленные применения. Например, в экономике оно описывает соотношение спрос - предложение.

Уже в простейшем случае, когда

$$\eta(x, \theta) = \theta_1 + \theta_2 x$$

уравнение регрессии имеет многочисленные применения. Например, в экономике оно описывает соотношение спрос - предложение.

Некоторые конкретные модели будут подробно рассмотрены в данном курсе.

Уже в простейшем случае, когда

$$\eta(x, \theta) = \theta_1 + \theta_2 x$$

уравнение регрессии имеет многочисленные применения. Например, в экономике оно описывает соотношение спрос - предложение.

Некоторые конкретные модели будут подробно рассмотрены в данном курсе.

Основные понятия, относящиеся к линейным по параметрам моделям, можно найти в учебном пособии

В.Б.Мелас, П.В.Шпелев "Планирование и анализ для регрессионных моделей СПб, изд-во СПбГУ, 2014.

Уже в простейшем случае, когда

$$\eta(x, \theta) = \theta_1 + \theta_2 x$$

уравнение регрессии имеет многочисленные применения. Например, в экономике оно описывает соотношение спрос - предложение.

Некоторые конкретные модели будут подробно рассмотрены в данном курсе.

Основные понятия, относящиеся к линейным по параметрам моделям, можно найти в учебном пособии

В.Б.Мелас, П.В.Шпелев "Планирование и анализ для регрессионных моделей СПб, изд-во СПбГУ, 2014.

По нелинейным моделям см. В.Б.Мелас "Локально оптимальные планы эксперимента". СПб, изд-во СПбГТУ, 1999.

Уравнение регрессии:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N.$$

Уравнение регрессии:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N.$$

Два разных типа задач по оценке параметров:

Уравнение регрессии:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N.$$

Два разных типа задач по оценке параметров:

- 1 Дана совместная выборка $(x_1, y_1), \dots, (x_N, y_N)$ и некоторая априорная информация о виде ошибок наблюдения $\varepsilon_1, \dots, \varepsilon_N$.

Необходимо найти функцию $\eta(x, \theta)$, которая наилучшим с некоторой точки зрения образом аппроксимирует экспериментальные данные, и оценить ее параметры.

Уравнение регрессии:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N.$$

Два разных типа задач по оценке параметров:

- 1 Дана совместная выборка $(x_1, y_1), \dots, (x_N, y_N)$ и некоторая априорная информация о виде ошибок наблюдения $\varepsilon_1, \dots, \varepsilon_N$.

Необходимо найти функцию $\eta(x, \theta)$, которая наилучшим с некоторой точки зрения образом аппроксимирует экспериментальные данные, и оценить ее параметры.

- 2 Дана функция $\eta(x, \theta)$ с точностью до неизвестных параметров θ и некоторая априорная информация о виде ошибок наблюдения $\varepsilon_1, \dots, \varepsilon_N$.

Необходимо таким образом выбрать условия проведения эксперимента $x_1, \dots, x_N$, чтобы по получаемой впоследствии выборке $(x_1, y_1), \dots, (x_N, y_N)$ можно было бы наилучшим с некоторой точки зрения образом оценить параметры θ .

Уравнение регрессии:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N.$$

Под планом эксперимента можно понимать совокупность не обязательно различных точек $x_1, \dots, x_N$, представляющих собой условия проведения экспериментов.

Уравнение регрессии:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N.$$

Под планом эксперимента можно понимать совокупность не обязательно различных точек $x_1, \dots, x_N$, представляющих собой условия проведения экспериментов.

Однако удобнее рассматривать план как дискретную вероятностную меру, приписывая каждой точке "вес" $1/N$.

Определение

Точный план эксперимента — дискретная вероятностная мера

$$\xi_N = \begin{bmatrix} x_1 & \dots & x_N \\ 1/N & \dots & 1/N \end{bmatrix},$$

где $x_1, \dots, x_N \in \mathcal{X}$ — не обязательно различны.

Уравнение регрессии:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N.$$

Под планом эксперимента можно понимать совокупность не обязательно различных точек $x_1, \dots, x_N$, представляющих собой условия проведения экспериментов.

Однако удобнее рассматривать план как дискретную вероятностную меру, приписывая каждой точке "вес" $1/N$.

Определение

Точный план эксперимента — дискретная вероятностная мера

$$\xi_N = \begin{bmatrix} x_1 & \dots & x_N \\ 1/N & \dots & 1/N \end{bmatrix},$$

где $x_1, \dots, x_N \in \mathcal{X}$ — не обязательно различны.

Будем пока считать, что точный план эксперимента фиксирован. Разберемся с тем, как оценивать параметры модели при фиксированном плане.

Линейные модели. Свойства оценок по методу наименьших квадратов

Уравнение регрессии:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N.$$

Наши предположения

- 1 Случайные ошибки $\varepsilon_1, \dots, \varepsilon_N$ обладают свойствами:
 $\mathbf{E}\varepsilon_i = 0$, $\mathbf{E}\varepsilon_i^2 = \sigma^2$, $\mathbf{E}\varepsilon_i\varepsilon_j = 0$, ($i \neq j$).
- 2 Параметры модели вещественные, т.е. $\Theta = \mathbb{R}^m$.

Линейные модели. Свойства оценок по методу наименьших квадратов

Уравнение регрессии:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N.$$

Наши предположения

- 1 Случайные ошибки $\varepsilon_1, \dots, \varepsilon_N$ обладают свойствами:
 $\mathbf{E}\varepsilon_i = 0$, $\mathbf{E}\varepsilon_i^2 = \sigma^2$, $\mathbf{E}\varepsilon_i\varepsilon_j = 0$, ($i \neq j$).
- 2 Параметры модели вещественные, т.е. $\Theta = \mathbb{R}^m$.

Регрессионная модель называется линейной (по параметрам), если она может быть записана в виде

$$\eta(x, \theta) = \theta_1 f_1(x) + \dots + \theta_m f_m(x),$$

где

$$f_1(x), \dots, f_m(x) -$$

заданные функции, например, $f_i = x^{i-1}$, $i = 1, 2, \dots, m$ (в этом случае модель называется полиномиальной).

Введем обозначения

$$Y = \begin{bmatrix} y_1 \\ \dots \\ y_N \end{bmatrix}, \quad X = \begin{bmatrix} f_1(x_1) & \dots & f_m(x_1) \\ \dots & \dots & \dots \\ f_1(x_N) & \dots & f_m(x_N) \end{bmatrix}, \quad \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \dots \\ \varepsilon_N \end{bmatrix}$$

Для линейной модели уравнение регрессии переписывается как

$$Y = X\theta + \varepsilon.$$

Гауссом был предложен метод наименьших квадратов.

Гауссом был предложен метод наименьших квадратов.

Оценка вектора параметров θ по методу наименьших квадратов определяется следующим образом

$$\hat{\theta} = \arg \min_{\theta \in R^m} (Y - X\theta)^T (Y - X\theta).$$

Гауссом был предложен метод наименьших квадратов.

Оценка вектора параметров θ по методу наименьших квадратов определяется следующим образом

$$\hat{\theta} = \arg \min_{\theta \in R^m} (Y - X\theta)^T (Y - X\theta).$$

Справедлива следующая лемма.

Lemma

Лемма 1. Для любой матрицы F и вектора Y соответствующих размерностей, система уравнений

$$X^T X \theta = X^T Y, \tag{1}$$

имеет решение. Причем вектор θ^ , удовлетворяющий системе, является МНК-оценкой.*

Доказательство леммы 1

Для произвольной матрицы A векторное пространство, порожденное ее столбцами, обозначим через $\mathcal{L}(A)$.

Доказательство леммы 1

Для произвольной матрицы A векторное пространство, порожденное ее столбцами, обозначим через $\mathcal{L}(A)$.

Покажем, что

$$\mathcal{L}(A^T) = \mathcal{L}(A^T A). \quad (2)$$

Действительно, для любого вектора b , ортогонального пространству $\mathcal{L}(A^T)$, имеет место равенство $b^T A^T = \mathbf{0} \Rightarrow b^T A^T A = \mathbf{0}$.

Доказательство леммы 1

Для произвольной матрицы A векторное пространство, порожденное ее столбцами, обозначим через $\mathcal{L}(A)$.

Покажем, что

$$\mathcal{L}(A^T) = \mathcal{L}(A^T A). \quad (2)$$

Действительно, для любого вектора b , ортогонального пространству $\mathcal{L}(A^T)$, имеет место равенство $b^T A^T = \mathbf{0} \Rightarrow b^T A^T A = \mathbf{0}$.

В обратную сторону, если вектор b ортогонален пространству $\mathcal{L}(A^T A)$, т.е. $b^T A^T A = \mathbf{0}$, то выполнено $\mathbf{0} = b^T A^T A b = (A b)^T A b$ и, следовательно, $b A^T = \mathbf{0}$.

Доказательство леммы 1

Для произвольной матрицы A векторное пространство, порожденное ее столбцами, обозначим через $\mathcal{L}(A)$.

Покажем, что

$$\mathcal{L}(A^T) = \mathcal{L}(A^T A). \quad (2)$$

Действительно, для любого вектора b , ортогонального пространству $\mathcal{L}(A^T)$, имеет место равенство $b^T A^T = \mathbf{0} \Rightarrow b^T A^T A = \mathbf{0}$.

В обратную сторону, если вектор b ортогонален пространству $\mathcal{L}(A^T A)$, т.е. $b^T A^T A = \mathbf{0}$, то выполнено $\mathbf{0} = b^T A^T A b = (A b)^T A b$ и, следовательно, $b A^T = \mathbf{0}$.

Из равенства (2) автоматически следует, что для любого вектора $X^T Y \in \mathcal{L}(X^T)$ существует вектор $X^T X \theta^* \in \mathcal{L}(X^T X)$ такой, что $X^T X \theta^* = X^T Y$.

Покажем теперь, что любое решение уравнения (1) является МНК-оценкой, т.е. минимизирует функцию

$$(Y - X\theta)^T (Y - X\theta)$$

Покажем теперь, что любое решение уравнения (1) является МНК-оценкой, т.е. минимизирует функцию

$$(Y - X\theta)^T (Y - X\theta)$$

Обозначим через $\hat{\theta}$ произвольное решение (1), имеем:

$$\begin{aligned} (Y - X\theta)^T (Y - X\theta) &= \\ (Y - X\hat{\theta} + X(\hat{\theta} - \theta))^T (Y - X\hat{\theta} + X(\hat{\theta} - \theta)) &\stackrel{*}{=} \\ (Y - X\hat{\theta})^T (Y - X\hat{\theta}) + (\hat{\theta} - \theta)^T X^T X (\hat{\theta} - \theta) &\geq \\ (Y - X\hat{\theta})^T (Y - X\hat{\theta}). \end{aligned}$$

Покажем теперь, что любое решение уравнения (1) является МНК-оценкой, т.е. минимизирует функцию

$$(Y - X\theta)^T (Y - X\theta)$$

Обозначим через $\hat{\theta}$ произвольное решение (1), имеем:

$$\begin{aligned} (Y - X\theta)^T (Y - X\theta) &= \\ (Y - X\hat{\theta} + X(\hat{\theta} - \theta))^T (Y - X\hat{\theta} + X(\hat{\theta} - \theta)) &\stackrel{*}{=} \\ (Y - X\hat{\theta})^T (Y - X\hat{\theta}) + (\hat{\theta} - \theta)^T X^T X (\hat{\theta} - \theta) &\geq \\ (Y - X\hat{\theta})^T (Y - X\hat{\theta}). \end{aligned}$$

Равенство " *" выполнено в силу того, что $\hat{\theta}$ является решением уравнения (1) и, следовательно,

$$(\hat{\theta} - \theta)^T X^T (Y - X\hat{\theta}) = (\hat{\theta} - \theta)^T (X^T Y - X^T X \hat{\theta}) = 0$$

Таким образом, минимум $(Y - X\theta)^T (Y - X\theta)$ достигается при $\theta = \hat{\theta}$. Лемма доказана.

Заметим, что если матрица $X^T X$ невырожденная, то система (1) имеет единственное решение:

$$\hat{\theta} = (X^T X)^{-1} X^T Y \quad (3)$$

Заметим, что если матрица $X^T X$ невырожденная, то система (1) имеет единственное решение:

$$\hat{\theta} = (X^T X)^{-1} X^T Y \quad (3)$$

Требования, предъявляемые к оценкам:

Заметим, что если матрица $X^T X$ невырожденная, то система (1) имеет единственное решение:

$$\hat{\theta} = (X^T X)^{-1} X^T Y \quad (3)$$

Требования, предъявляемые к оценкам:

- 1 $E\hat{\theta} = \theta$ — несмещенность,

Заметим, что если матрица $X^T X$ невырожденная, то система (1) имеет единственное решение:

$$\hat{\theta} = (X^T X)^{-1} X^T Y \quad (3)$$

Требования, предъявляемые к оценкам:

- 1 $E\hat{\theta} = \theta$ — несмещенность,
- 2 $\hat{\theta} = SY$ — линейность,

Заметим, что если матрица $X^T X$ невырожденная, то система (1) имеет единственное решение:

$$\hat{\theta} = (X^T X)^{-1} X^T Y \quad (3)$$

Требования, предъявляемые к оценкам:

- ❶ $\mathbf{E}\hat{\theta} = \theta$ — несмещенность,
- ❷ $\hat{\theta} = SY$ — линейность,
- ❸ $\forall z \in \mathbb{R}^m, \forall \tilde{\theta} : \mathbf{E}\tilde{\theta} = \theta, \mathbf{D}z^T(\hat{\theta} - \theta) \leq \mathbf{D}z^T(\tilde{\theta} - \theta)$ — минимальность дисперсии.

Заметим, что если матрица $X^T X$ невырожденная, то система (1) имеет единственное решение:

$$\hat{\theta} = (X^T X)^{-1} X^T Y \quad (3)$$

Требования, предъявляемые к оценкам:

- ❶ $\mathbf{E}\hat{\theta} = \theta$ — несмещенность,
- ❷ $\hat{\theta} = SY$ — линейность,
- ❸ $\forall z \in \mathbb{R}^m, \forall \tilde{\theta} : \mathbf{E}\tilde{\theta} = \theta, \mathbf{D}z^T(\hat{\theta} - \theta) \leq \mathbf{D}z^T(\tilde{\theta} - \theta)$ — минимальность дисперсии.

Будем предполагать, что матрица $X^T X$ - не вырожденная.

Заметим, что если матрица $X^T X$ невырожденная, то система (1) имеет единственное решение:

$$\hat{\theta} = (X^T X)^{-1} X^T Y \quad (3)$$

Требования, предъявляемые к оценкам:

- ❶ $E\hat{\theta} = \theta$ — несмещенность,
- ❷ $\hat{\theta} = SY$ — линейность,
- ❸ $\forall z \in \mathbb{R}^m, \forall \tilde{\theta} : E\tilde{\theta} = \theta, D_z^T(\hat{\theta} - \theta) \leq D_z^T(\tilde{\theta} - \theta)$ — минимальность дисперсии.

Будем предполагать, что матрица $X^T X$ - не вырожденная.

Теорема (Гаусса-Маркова)

Если матрица $X^T X$ - не вырожденная, то оценка по методу наименьших квадратов (3) является наилучшей (в смысле требования 3) оценкой в классе линейных несмещенных оценок. Кроме того, ковариационная матрица оценки имеет вид:

$$D\hat{\theta} = \sigma^2 (X^T X)^{-1}.$$

Рассмотрим для примера линейную по параметрам модель

$$y_j = a + bt_j + \epsilon_j, \quad j = 1, \dots, N,$$

где $t_1, \dots, t_N$ — некоторые заданные вещественные числа.

$$X = \begin{pmatrix} 1 & t_1 \\ \vdots & \vdots \\ 1 & t_N \end{pmatrix}, \quad X^T X = \begin{pmatrix} N & \sum_i t_i \\ \sum_i t_i & \sum_i t_i^2 \end{pmatrix}.$$

Рассмотрим для примера линейную по параметрам модель

$$y_j = a + bt_j + \epsilon_j, \quad j = 1, \dots, N,$$

где $t_1, \dots, t_N$ — некоторые заданные вещественные числа.

$$X = \begin{pmatrix} 1 & t_1 \\ \vdots & \vdots \\ 1 & t_N \end{pmatrix}, \quad X^T X = \begin{pmatrix} N & \sum_i t_i \\ \sum_i t_i & \sum_i t_i^2 \end{pmatrix}.$$

Применяя известную формулу для обратной матрицы, получаем

$$(X^T X)^{-1} = \begin{pmatrix} \frac{\sum_i t_i^2}{\Delta} & \frac{-\sum_i t_i}{\Delta} \\ \frac{-\sum_i t_i}{\Delta} & \frac{N}{\Delta} \end{pmatrix}, \quad \Delta = N \sum_i t_i^2 - \left(\sum_i t_i \right)^2.$$

Рассмотрим для примера линейную по параметрам модель

$$y_j = a + bt_j + \epsilon_j, \quad j = 1, \dots, N,$$

где $t_1, \dots, t_N$ — некоторые заданные вещественные числа.

$$X = \begin{pmatrix} 1 & t_1 \\ \vdots & \vdots \\ 1 & t_N \end{pmatrix}, \quad X^T X = \begin{pmatrix} N & \sum_i t_i \\ \sum_i t_i & \sum_i t_i^2 \end{pmatrix}.$$

Применяя известную формулу для обратной матрицы, получаем

$$(X^T X)^{-1} = \begin{pmatrix} \frac{\sum_i t_i^2}{\Delta} & \frac{-\sum_i t_i}{\Delta} \\ \frac{-\sum_i t_i}{\Delta} & \frac{N}{\Delta} \end{pmatrix}, \quad \Delta = N \sum_i t_i^2 - \left(\sum_i t_i \right)^2.$$

Искомая оценка

$$\begin{pmatrix} \hat{a} \\ \hat{b} \end{pmatrix} = (X^T X)^{-1} X^T Y = \begin{pmatrix} \frac{\sum_i t_i^2 \sum_i y_i - \sum_i t_i \sum_i y_i t_i}{N \sum_i t_i^2 - \left(\sum_i t_i \right)^2} \\ \frac{\sum_i y_i - \frac{\sum_i t_i \sum_i y_i t_i}{N \sum_i t_i^2 - \left(\sum_i t_i \right)^2}}{N} \end{pmatrix}.$$

Доказательство теоремы Гаусса-Маркова.

Для доказательства нам потребуются следующие вспомогательные утверждения:

Lemma

Лемма 2. МНК-оценка является линейно несмещенной оценкой (т.е. для нее выполнены требования (a)-(b)).

Доказательство леммы 2 Линейность МНК-оценки очевидна ($S = (X^T X)^{-1} X^T$), проверим несмещенность. Посчитаем математическое ожидание:

$$E\hat{\theta} = ESY = SEY = SE(X\theta + \epsilon) = SX\theta = (X^T X)^{-1} X^T X\theta = \theta$$

Лемма доказана.



Теперь сформулируем более общее утверждение о несмещенности оценки.

Lemma

Лемма 3. Для того, чтобы оценка $\tilde{\theta} = AY$ была несмещенной, необходимо и достаточно, чтобы выполнялось равенство:

$$AX = I$$

Эта лемма является основным инструментом доказательства теоремы Гаусса-Маркова.

Теперь сформулируем более общее утверждение о несмещенности оценки.

Lemma

Лемма 3. Для того, чтобы оценка $\tilde{\theta} = AY$ была несмещенной, необходимо и достаточно, чтобы выполнялось равенство:

$$AX = I$$

Эта лемма является основным инструментом доказательства теоремы Гаусса-Маркова.

Доказательство леммы 3

Достаточность. Пусть $AX = I$, тогда

$$\begin{aligned} E\tilde{\theta} &= EAY = \\ AE(X\theta + \epsilon) &= \underbrace{AX}_I \theta = \theta. \end{aligned}$$

Таким образом, оценка $\tilde{\theta} = AY$ является несмещенной оценкой.

Необходимость. Пусть, теперь, выполнено $E\tilde{\theta} = \theta$, т.е. оценка несмещенная. Тогда получаем $E\tilde{\theta} = AX\theta = \theta$. Следовательно,

$$AX\theta = \theta.$$

Необходимость. Пусть, теперь, выполнено $E\tilde{\theta} = \theta$, т.е. оценка несмещенная. Тогда получаем $E\tilde{\theta} = AX\theta = \theta$. Следовательно,

$$AX\theta = \theta.$$

Так как это равенство должно быть выполнено для любого вектора

θ , можем в качестве него выбрать вектор $e_i = (0, \dots, 0, 1, 0, \dots, 0)^T$ с единицей на i -м месте.

Необходимость. Пусть, теперь, выполнено $E\tilde{\theta} = \theta$, т.е. оценка несмещенная. Тогда получаем $E\tilde{\theta} = AX\theta = \theta$. Следовательно,

$$AX\theta = \theta.$$

Так как это равенство должно быть выполнено для любого вектора

θ , можем в качестве него выбрать вектор $e_i = (0, \dots, 0, 1, 0, \dots, 0)^T$ с единицей на i -м месте.

Проделав это для всех $i = 1, \dots, m$, получим систему уравнений $AX = I$, что завершает доказательство.



Lemma

Лемма 4. В предположениях теоремы Гаусса - Маркова дисперсионная матрица любой линейной несмещенной оценки $\tilde{\theta} = AY$ имеет вид:

$$D_{\tilde{\theta}} = \sigma^2 AA^T.$$

В частном случае, если $\tilde{\theta}$ - МНК-оценка, то

$$D_{\tilde{\theta}} = \sigma^2 (X^T X)^{-1}.$$

Lemma

Лемма 4. В предположениях теоремы Гаусса - Маркова дисперсионная матрица любой линейной несмещенной оценки $\tilde{\theta} = AY$ имеет вид:

$$D_{\tilde{\theta}} = \sigma^2 AA^T.$$

В частном случае, если $\tilde{\theta}$ - МНК-оценка, то

$$D_{\tilde{\theta}} = \sigma^2 (X^T X)^{-1}.$$

Доказательство леммы 4 вычислим дисперсионную матрицу оценки $\tilde{\theta}$:

$$D_{\tilde{\theta}} = E(\tilde{\theta} - \theta)(\tilde{\theta} - \theta)^T = E(AY - \theta)(AY - \theta)^T = EAYY^T A^T - \theta\theta^T,$$

так как $EAY = (EY^T A^T)^T = \theta$.

Lemma

Лемма 4. В предположениях теоремы Гаусса - Маркова дисперсионная матрица любой линейной несмещенной оценки $\tilde{\theta} = AY$ имеет вид:

$$D_{\tilde{\theta}} = \sigma^2 AA^T.$$

В частном случае, если $\tilde{\theta}$ - МНК-оценка, то

$$D_{\tilde{\theta}} = \sigma^2 (X^T X)^{-1}.$$

Доказательство леммы 4 вычислим дисперсионную матрицу оценки $\tilde{\theta}$:

$$D_{\tilde{\theta}} = E(\tilde{\theta} - \theta)(\tilde{\theta} - \theta)^T = E(AY - \theta)(AY - \theta)^T = EAYY^T A^T - \theta\theta^T,$$

так как $EAY = (EY^T A^T)^T = \theta$. С другой стороны,

$$\begin{aligned} EAYY^T A^T &= AE(YY^T)A^T = AE(X\theta + \epsilon)(X\theta + \epsilon)^T A^T = \\ &= \underbrace{AX}_{\theta} \theta^T \underbrace{X^T A^T}_{\theta^T} + \sigma^2 AA^T = \theta\theta^T + \sigma^2 AA^T \end{aligned}$$

Lemma

Лемма 4. В предположениях теоремы Гаусса - Маркова дисперсионная матрица любой линейной несмещенной оценки $\tilde{\theta} = AY$ имеет вид:

$$D_{\tilde{\theta}} = \sigma^2 AA^T.$$

В частном случае, если $\tilde{\theta}$ - МНК-оценка, то

$$D_{\tilde{\theta}} = \sigma^2 (X^T X)^{-1}.$$

Доказательство леммы 4 вычислим дисперсионную матрицу оценки $\tilde{\theta}$:

$$D_{\tilde{\theta}} = E(\tilde{\theta} - \theta)(\tilde{\theta} - \theta)^T = E(AY - \theta)(AY - \theta)^T = EAYY^T A^T - \theta\theta^T,$$

так как $EAY = (EY^T A^T)^T = \theta$. С другой стороны,

$$EAYY^T A^T = AE(YY^T)A^T = AE(X\theta + \epsilon)(X\theta + \epsilon)^T A^T =$$

$$\underbrace{AX}_{\theta} \theta \theta^T \underbrace{X^T A^T}_{\theta^T} + \sigma^2 AA^T = \theta\theta^T + \sigma^2 AA^T$$

Вернемся теперь к доказательству теоремы. Проверим, что выполняется неравенство:

$$D_{\hat{\theta}} \leq D_{\tilde{\theta}}.$$

Вернемся теперь к доказательству теоремы. Проверим, что выполняется неравенство:

$$D_{\hat{\theta}} \leq D_{\tilde{\theta}}.$$

Обозначим матрицу $(X^T X)^{-1} X^T$ через S . Для произвольной несмещенной оценки $\tilde{\theta} = AY$ имеем (в силу Леммы 4)

$$D_{\tilde{\theta}} = \sigma^2 AA^T,$$

а для оценки метода наименьших квадратов

$$D_{\hat{\theta}} = \sigma^2 SS^T,$$

. Значит нам достаточно доказать, что

$$AA^T \geq SS^T.$$

Вернемся теперь к доказательству теоремы. Проверим, что выполняется неравенство:

$$D_{\hat{\theta}} \leq D_{\tilde{\theta}}.$$

Обозначим матрицу $(X^T X)^{-1} X^T$ через S . Для произвольной несмещенной оценки $\tilde{\theta} = AY$ имеем (в силу Леммы 4)

$$D_{\tilde{\theta}} = \sigma^2 AA^T,$$

а для оценки метода наименьших квадратов

$$D_{\hat{\theta}} = \sigma^2 SS^T,$$

. Значит нам достаточно доказать, что

$$AA^T \geq SS^T.$$

Заметим, что для произвольной матрицы L

$$LL^T \geq 0,$$

где 0 - нулевая матрица. Подставляя сюда $L = A - S$ и произведя вычисления с учетом того, что $AX = I$, получим

$$LL^T = AA^T - SS^T \geq 0, AA^T \geq SS^T.$$

МНК-оценка в вырожденном случае.

В предыдущем параграфе мы рассматривали задачу нахождения МНК-оценки в случае, когда матрица $X^T X$ невырожденная. В данном параграфе мы обобщим полученные результаты для когда ранг матрицы $X^T X$ меньше числа оцениваемых параметров.

МНК-оценка в вырожденном случае.

В предыдущем параграфе мы рассматривали задачу нахождения МНК-оценки в случае, когда матрица $X^T X$ невырожденная. В данном параграфе мы обобщим полученные результаты для когда ранг матрицы $X^T X$ меньше числа оцениваемых параметров.

Заметим, что матрица $X^T X$ является вырожденной, например, в задачах дисперсионного анализа.

МНК-оценка в вырожденном случае.

В предыдущем параграфе мы рассматривали задачу нахождения МНК-оценки в случае, когда матрица $X^T X$ невырожденная. В данном параграфе мы обобщим полученные результаты для случая, когда ранг матрицы $X^T X$ меньше числа оцениваемых параметров.

Заметим, что матрица $X^T X$ является вырожденной, например, в задачах дисперсионного анализа.

Итак, пусть $X^T X$ - вырожденная матрица. В этом случае, под МНК-оценкой, по-прежнему, понимается вектор, минимизирующий $\|Y - X\theta\|^2$ и, согласно лемме 1, являющийся решением нормального уравнения

$$X^T X \theta = X^T Y.$$

МНК-оценка в вырожденном случае.

В предыдущем параграфе мы рассматривали задачу нахождения МНК-оценки в случае, когда матрица $X^T X$ невырожденная. В данном параграфе мы обобщим полученные результаты для случая, когда ранг матрицы $X^T X$ меньше числа оцениваемых параметров.

Заметим, что матрица $X^T X$ является вырожденной, например, в задачах дисперсионного анализа.

Итак, пусть $X^T X$ - вырожденная матрица. В этом случае, под МНК-оценкой, по-прежнему, понимается вектор, минимизирующий $\|Y - X\theta\|^2$ и, согласно лемме 1, являющийся решением нормального уравнения

$$X^T X \theta = X^T Y.$$

Как уже было показано, эта система уравнений совместна. Однако, в вырожденном случае, она имеет бесконечное множество решений, т.е. вектор $\hat{\theta}$, являющийся её решением, определен не однозначно.

Пусть имеется произвольная система уравнений $Ax = y$, где $x \in R^n, y \in R^m$ - вектора , $A \in R^{n \times m}$ - матрица соответствующей размерности (не обязательно квадратная).

Пусть имеется произвольная система уравнений $Ax = y$, где $x \in R^n, y \in R^m$ - вектора, $A \in R^{n \times m}$ - матрица соответствующей размерности (не обязательно квадратная).

Определение. Обобщенно-обратной для матрицы A , называется матрица порядка $n \times m$, обозначаемая A^- , такая, что для любого вектора y , для которого система $Ax = y$ совместна, вектор $x = A^-y$ является ее решением.

Пусть имеется произвольная система уравнений $Ax = y$, где $x \in R^n, y \in R^m$ - вектора, $A \in R^{n \times m}$ - матрица соответствующей размерности (не обязательно квадратная).

Определение. Обобщенно-обратной для матрицы A , называется матрица порядка $n \times m$, обозначаемая A^- , такая, что для любого вектора y , для которого система $Ax = y$ совместна, вектор $x = A^-y$ является ее решением.

Для начала, отметим одно важное свойство, которым обладает матрица A^- , а потом ответим на вопрос о ее существовании.

Lemma

Лемма 5. Для того, чтобы матрица B являлась обобщенно-обратной матрицей для матрицы A , необходимо и достаточно, чтобы B удовлетворяла равенству:

$$ABA = A.$$

Доказательство леммы 5

Пусть для матрицы A существует обобщенно-обратная матрица $B = A^-$. Выберем в качестве y i -ый столбец матрицы A . Система

$$Ax = a_i,$$

очевидно, совместна. Ее решение существует. Например, $x = e_i$. Вектор $x = A^- a_i$, по определению, является решением этой системы.

Доказательство леммы 5

Пусть для матрицы A существует обобщенно-обратная матрица $B = A^-$. Выберем в качестве y i -ый столбец матрицы A . Система

$$Ax = a_i,$$

очевидно, совместна. Ее решение существует. Например, $x = e_i$. Вектор $x = A^- a_i$, по определению, является решением этой системы. Из этого следует, что

$$Ax = AA^- a_i = a_i \quad \forall i,$$

что, в свою очередь, означает, что выполнено равенство $AA^- A = A$.

Доказательство леммы 5

Пусть для матрицы A существует обобщенно-обратная матрица $B = A^-$. Выберем в качестве y i -ый столбец матрицы A . Система

$$Ax = a_i,$$

очевидно, совместна. Ее решение существует. Например, $x = e_i$. Вектор $x = A^- a_i$, по определению, является решением этой системы. Из этого следует, что

$$Ax = AA^- a_i = a_i \quad \forall i,$$

что, в свою очередь, означает, что выполнено равенство $AA^- A = A$.

Пусть, теперь, система $Ax = y$ совместна и матрица B удовлетворяет равенству

$$ABA = A.$$

Тогда, умножая обе части этого равенства справа на x , получим

$$AB \underbrace{Ax}_y = \underbrace{Ax}_y \Rightarrow AB y = y,$$

и, следовательно, вектор $x = By$ является решением системы $Ax = y$.

Доказательство леммы 5

Пусть для матрицы A существует обобщенно-обратная матрица $B = A^-$. Выберем в качестве y i -ый столбец матрицы A . Система

$$Ax = a_i,$$

очевидно, совместна. Ее решение существует. Например, $x = e_i$. Вектор $x = A^- a_i$, по определению, является решением этой системы. Из этого следует, что

$$Ax = AA^- a_i = a_i \quad \forall i,$$

что, в свою очередь, означает, что выполнено равенство $AA^- A = A$.

Пусть, теперь, система $Ax = y$ совместна и матрица B удовлетворяет равенству

$$ABA = A.$$

Тогда, умножая обе части этого равенства справа на x , получим

$$AB \underbrace{Ax}_y = \underbrace{Ax}_y \Rightarrow AB y = y,$$

и, следовательно, вектор $x = By$ является решением системы $Ax = y$.

Теперь рассмотрим вопрос существования обобщенно-обратной матрицы. Справедлива следующая лемма.

Lemma

Лемма 6. Для всякой матрицы A существует о.о. матрица A^- .

Доказательство леммы Сперва рассмотрим случай, когда A - симметричная квадратная матрица. По теореме о спектральном разложении, в этом случае, матрицу A можно представить в виде

$$A = P\Lambda P^T, \quad PP^T = P^TP = I,$$

Λ - матрица, на диагонали которой стоят собственные числа матрицы A , а внедиагональные элементы равны 0. Без ограничения общности можно считать, что матрица Λ имеет вид:

$$\Lambda = \begin{pmatrix} \Lambda_1 & 0 \\ 0 & 0 \end{pmatrix},$$

где Λ_1 имеет ненулевые диагональные элементы. Положим,

$$A^- = P\Lambda^-P^T, \quad \Lambda^- = \begin{pmatrix} \Lambda_1^{-1} & 0 \\ 0 & 0 \end{pmatrix}.$$

Проверим, что $AA^{-}A = A$:

$$AA^{-}A = P\Lambda P^T P\Lambda^{-}P^T P\Lambda P^T = P\Lambda\Lambda^{-}\Lambda P^T = P\Lambda P^T = A.$$

Следовательно, по лемме 5, матрица A^{-} является обобщенно-обратной.

Для произвольной матрицы A существует представление $A = B\Lambda C$, где B и C - невырожденные матрицы, Λ - диагональная. Так же, как и в предыдущем случае, положим:

$$\Lambda = \begin{pmatrix} \Lambda_1 & 0 \\ 0 & 0 \end{pmatrix}, \quad \Lambda^{-} = \begin{pmatrix} \Lambda_1^{-1} & 0 \\ 0 & 0 \end{pmatrix}, \quad A^{-} = C^{-1}\Lambda^{-}B^{-1}.$$

Несложно проверить, что для A^{-} выполнено равенство $AA^{-}A = A$:

$$AA^{-}A = B\Lambda C C^{-1}\Lambda^{-}B^{-1}B\Lambda C = B\Lambda\Lambda^{-}\Lambda C = B\Lambda C = A.$$

Следовательно, по лемме 5, матрица A^{-} является обобщенно-обратной. Лемма доказана.



Справедлива следующая теорема.

Theorem

Пусть A^- какая-либо обобщенно-обратная для A матрица. И, пусть, $H = A^- A$. Тогда,

- (a) $H^2 = H$, т.е. матрица H идемпотентная;
- (b) $AH = A$ и ранг A равен рангу H и $\text{tr}(H)$;
- (c) Общее решение системы уравнений $Ax = 0$ имеет вид $x = (H - I)z$, где z -произвольный вектор;
- (d) Общее решение совместной системы уравнений $Ax = y$ имеет вид $x = A^-y + (H - I)z$, где z - произвольный вектор;
- (e) Произведение Tx принимает единственное значение для всех x , удовлетворяющих системе $Ax = y$, тогда и только тогда, когда $TH = T$.

Доказательство теоремы. Пункты (a) – (e) следуют из леммы 5. Прокомментируем вторую часть пункта (b) : Пусть ранг A равен k .

$$\begin{aligned} \operatorname{tr} A^{-1} A &= \operatorname{tr} C^{-1} \Lambda^{-1} B^{-1} B \Lambda C = \\ \operatorname{tr} C^{-1} \Lambda^{-1} \Lambda C &= \operatorname{tr} \Lambda^{-1} \Lambda C C^{-1} = \operatorname{tr} \Lambda^{-1} \Lambda = \operatorname{tr} I_k = k, \end{aligned}$$

где I_k диагональная матрица с k единицами на главной диагонали k -ранг матрицы A . Остальные ее элементы - нули. Мы воспользовались известным результатом $\operatorname{tr} AB = \operatorname{tr} BA$ (для любых согласованных матриц A, B). Теорема доказана.



В случае, когда матрица X имеет ранг меньший m , невозможно несмещенно оценить все параметры регрессионной модели $(Y, X\theta, \Sigma)$. Однако, можно оценить некоторые параметрические функции $\tau = T\theta$. Вид оценки и условия оцениваемости определяются, в этом случае, в следующей теореме, являющейся аналогом теоремы Гаусса-Маркова для вырожденной матрицы $X^T X$.

Theorem

Для классической регрессионной модели и вектора ошибок, удовлетворяющего условию $E\epsilon = 0$,

- (1) параметрическая функция $\tau = T\theta$ ($T \in R^{k \times m}$, $k \in \{1, \dots, m\}$) оценивается тогда и только тогда, когда

$$T(X^T X)^{-1} X^T X = T.$$

- (2) Если выполнено условие (1), оценка для τ имеет вид:

$$\hat{\tau} = T(X^T X)^{-1} X^T Y,$$

определена однозначно, и являются наилучшей линейной несмещенной оценкой. Ковариационная матрица оценки $\hat{\tau}$ имеет вид:

$$D_{\hat{\tau}} = \sigma^2 D, \quad D = T(X^T X)^{-1} T^T.$$

Нелинейные модели. Асимптотические свойства оценок параметров

Вернемся снова к общему уравнению регрессии:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N.$$

Пусть теперь $\eta(x, \theta)$ не обязательно линейная.

Нелинейные модели. Асимптотические свойства оценок параметров

Вернемся снова к общему уравнению регрессии:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N.$$

Пусть теперь $\eta(x, \theta)$ не обязательно линейная. Будем предполагать, что

Случайные ошибки $\varepsilon_1, \dots, \varepsilon_N$ независимы, одинаково распределены и обладают свойствами:

- 1 $\mathbf{E}\varepsilon_i = 0$,
- 2 $\mathbf{E}\varepsilon_i^2 = \sigma^2$.

Нелинейные модели. Асимптотические свойства оценок параметров

Вернемся снова к общему уравнению регрессии:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N.$$

Пусть теперь $\eta(x, \theta)$ не обязательно линейная. Будем предполагать, что

Случайные ошибки $\varepsilon_1, \dots, \varepsilon_N$ независимы, одинаково распределены и обладают свойствами:

- 1 $\mathbf{E}\varepsilon_i = 0$,
- 2 $\mathbf{E}\varepsilon_i^2 = \sigma^2$.

Оценка вектора θ по методу наименьших квадратов определяется как решение экстремальной задачи:

$$\hat{\theta} = \arg \min_{\theta \in \mathbb{R}^m} \sum_{i=1}^N (\eta(x_i, \theta) - y_i)^2.$$

Нелинейные модели. Асимптотические свойства оценок параметров

Вернемся снова к общему уравнению регрессии:

$$y_i = \eta(x_i, \theta) + \varepsilon_i, \quad i = 1, \dots, N.$$

Пусть теперь $\eta(x, \theta)$ не обязательно линейная. Будем предполагать, что

Случайные ошибки $\varepsilon_1, \dots, \varepsilon_N$ независимы, одинаково распределены и обладают свойствами:

- 1 $\mathbf{E}\varepsilon_i = 0$,
- 2 $\mathbf{E}\varepsilon_i^2 = \sigma^2$.

Оценка вектора θ по методу наименьших квадратов определяется как решение экстремальной задачи:

$$\hat{\theta} = \arg \min_{\theta \in \mathbb{R}^m} \sum_{i=1}^N (\eta(x_i, \theta) - y_i)^2.$$

Обсудим, какими асимптотическими свойствами обладает эта оценка.

Введем предположения:

- 1 Функция регрессии $\eta(x, \theta)$ непрерывна по x и θ ;

Введем предположения:

- 1 Функция регрессии $\eta(x, \theta)$ непрерывна по x и θ ;
- 2 Существует ξ такой что $\mathcal{L}(\xi_N) \Rightarrow \mathcal{L}(\xi)$, т.е.

$$\int_{\mathcal{X}} g(x) d\xi_N(x) \rightarrow \int_{\mathcal{X}} g(x) d\xi(x), \quad \forall g \in C(\mathcal{X});$$

Введем предположения:

- ❶ Функция регрессии $\eta(x, \theta)$ непрерывна по x и θ ;
- ❷ Существует ξ такой что $\mathcal{L}(\xi_N) \Rightarrow \mathcal{L}(\xi)$, т.е.

$$\int_{\mathcal{X}} g(x) d\xi_N(x) \rightarrow \int_{\mathcal{X}} g(x) d\xi(x), \quad \forall g \in C(\mathcal{X});$$

- ❸ Для любых $\theta, \bar{\theta} \in \Theta$

$$\int_{\mathcal{X}} (\eta(x, \theta) - \eta(x, \bar{\theta}))^2 d\xi(x) = 0 \Leftrightarrow \theta = \bar{\theta};$$

Введем предположения:

- ❶ Функция регрессии $\eta(x, \theta)$ непрерывна по x и θ ;
- ❷ Существует ξ такой что $\mathcal{L}(\xi_N) \Rightarrow \mathcal{L}(\xi)$, т.е.

$$\int_{\mathcal{X}} g(x) d\xi_N(x) \rightarrow \int_{\mathcal{X}} g(x) d\xi(x), \quad \forall g \in C(\mathcal{X});$$

- ❸ Для любых $\theta, \bar{\theta} \in \Theta$

$$\int_{\mathcal{X}} (\eta(x, \theta) - \eta(x, \bar{\theta}))^2 d\xi(x) = 0 \Leftrightarrow \theta = \bar{\theta};$$

- ❹ $\eta \in C_{\theta}^2(\mathcal{X} \times \Theta)$;

Введем предположения:

- ❶ Функция регрессии $\eta(x, \theta)$ непрерывна по x и θ ;
- ❷ Существует ξ такой что $\mathcal{L}(\xi_N) \Rightarrow \mathcal{L}(\xi)$, т.е.

$$\int_{\mathcal{X}} g(x) d\xi_N(x) \rightarrow \int_{\mathcal{X}} g(x) d\xi(x), \quad \forall g \in C(\mathcal{X});$$

- ❸ Для любых $\theta, \bar{\theta} \in \Theta$

$$\int_{\mathcal{X}} (\eta(x, \theta) - \eta(x, \bar{\theta}))^2 d\xi(x) = 0 \Leftrightarrow \theta = \bar{\theta};$$

- ❹ $\eta \in C_{\theta}^2(\mathcal{X} \times \Theta)$;
- ❺ Истинное значение параметра θ_u является внутренней точкой Θ ;

Введем предположения:

- ❶ Функция регрессии $\eta(x, \theta)$ непрерывна по x и θ ;
- ❷ Существует ξ такой что $\mathcal{L}(\xi_N) \Rightarrow \mathcal{L}(\xi)$, т.е.

$$\int_{\mathcal{X}} g(x) d\xi_N(x) \rightarrow \int_{\mathcal{X}} g(x) d\xi(x), \quad \forall g \in C(\mathcal{X});$$

- ❸ Для любых $\theta, \bar{\theta} \in \Theta$

$$\int_{\mathcal{X}} (\eta(x, \theta) - \eta(x, \bar{\theta}))^2 d\xi(x) = 0 \Leftrightarrow \theta = \bar{\theta};$$

- ❹ $\eta \in C_{\theta}^2(\mathcal{X} \times \Theta)$;
- ❺ Истинное значение параметра θ_u является внутренней точкой Θ ;
- ❻ Матрица

$$M(\xi, \theta) = \int_{\mathcal{X}} f(x, \theta) f^T(x, \theta) d\xi(x),$$

где $f(x, \theta) = \left[\frac{\partial \eta(x, \theta)}{\partial \theta_1}, \dots, \frac{\partial \eta(x, \theta)}{\partial \theta_m} \right]^T$ не вырождена при $\theta = \theta_u$.

Обозначим

$$\hat{\theta}_N = \arg \min_{\theta \in \mathbb{R}^m} \sum_{i=1}^N (\eta(x_i, \theta) - y_i)^2. \quad (4)$$

Теорема

Если выполнены предположения 1–3, то последовательность МНК-оценок сильно состоятельна, т.е. при $N \rightarrow \infty$

$$\hat{\theta}_N \rightarrow \theta_u$$

с вероятностью 1, где $\hat{\theta}_N$ определено формулой (4).

Если дополнительно выполняются предположения 4–6, то последовательность случайных векторов

$$\sqrt{N}(\hat{\theta}_N - \theta_u) \Rightarrow \mathcal{N}(0, \Sigma),$$

ковариационная матрица $\Sigma = \sigma^2 M^{-1}(\xi, \theta_u)$.

Доказательство теоремы можно найти в работе

Jennrich, R. J. (1969). Asymptotic properties of non-linear least squares estimators // Ann. Math. Stat., 40, 633–643.

Доказательство теоремы можно найти в работе

Jennrich, R. J. (1969). Asymptotic properties of non-linear least squares estimators // Ann. Math. Stat., 40, 633–643.

- ❶ Нелинейные модели обычно возникают как решения систем уравнений, описывающих поведение некоторого реального процесса.

Доказательство теоремы можно найти в работе

Jennrich, R. J. (1969). Asymptotic properties of non-linear least squares estimators // Ann. Math. Stat., 40, 633–643.

- 1 Нелинейные модели обычно возникают как решения систем уравнений, описывающих поведение некоторого реального процесса.
- 2 Параметры нелинейных моделей имеют, как правило, четкую предметную интерпретацию и находятся из анализа результатов эксперимента.

Доказательство теоремы можно найти в работе

Jennrich, R. J. (1969). Asymptotic properties of non-linear least squares estimators // Ann. Math. Stat., 40, 633–643.

- ❶ Нелинейные модели обычно возникают как решения систем уравнений, описывающих поведение некоторого реального процесса.
- ❷ Параметры нелинейных моделей имеют, как правило, четкую предметную интерпретацию и находятся из анализа результатов эксперимента.
- ❸ Рассмотрим два примера.